

To be FAIR or to be RIGHT?

Methodische Validität in der Entwicklung menschzugewandter Forschungssoftware

Julian Dehne

RSE-Seminar, Potsdam

2026-07-23

Ausgangspunkt

Forschungssoftware (RS) ist heute Standardbestandteil des Forschungsprozesses (Brett et al. 2017). Der RSE-Diskurs dreht sich fast vollständig um

- ▶ **Reproduzierbarkeit** (FAIR4RS (Barker et al. 2022))
- ▶ **Nachnutzbarkeit**
- ▶ **Softwarequalität** im klassischen SE-Sinn

Das sind alles Fragen der **Reliabilität**.

These des Vortrags

Die Frage, ob die Software *misst*, *was sie messen soll*, also die **Validität**, ist im RSE-Diskurs weitgehend unbearbeitet — und genau dort, wo Menschen die Software bedienen, wird sie kritisch.

Die RSE- und Open-Science-Bewegung stammt aus dem *scientific computing* und damit aus den Naturwissenschaften (Dehne et al. 2025).

Dadurch sind ganze Felder vom Diskurs abgekoppelt:

- ▶ Bildungstechnologien
- ▶ Mensch-Computer-Interaktion
- ▶ Computational Social Sciences

Dort sind Menschen **gleichzeitig Nutzende der Software und Gegenstand der Forschung**. Die üblichen Modelle, Pipelines und Ideale lassen sich nicht übertragen, ohne die zugrundeliegenden Annahmen zu ändern.

“How to (better) organize software-centric scientific processes?” — offene Forschungsfrage des Feldes (Felderer et al. 2025)

Forschungssoftware wird hier eng gefasst: Software, die *für eine bestimmte Studie oder Studiengruppe mit geplanter menschlicher Interaktion* entwickelt wurde — eine Spezifikation von (Gruenpeter et al. 2021).

Bewusste Einschränkung auf Software, die noch **inkubiert** und noch keine Maintainer-Community gebildet hat. Damit liegt der Fokus auf der **Designphase**.

Forschungsparadigma nach (Kuhn 1994): symbolische Generalisierungen, Modelle, Werte, Best-Practice-Muster.

Der Wissenschaftsrat (Wissenschaftsrat 2012) unterscheidet *empirische, gestaltungsbasierte, hermeneutische* und *theoretische* Forschung.

Gütekriterien: woher kommt der Maßstab?

Die Sozialwissenschaften diskutieren diese Frage seit Jahrzehnten (Schnell et al. 1999).

Kriterium	Bedeutung	Status im RSE-Diskurs
Reliabilität	Wiederholte Messung ergibt dasselbe Ergebnis	Gut abgedeckt (FAIR, Tests, Requirements)
Validität	Das Instrument misst, was es messen soll	Weitgehend unbearbeitet
Objektivität	Unabhängigkeit von der durchführenden Person	Außerhalb des Scope dieser Arbeit

Klassisches Beispiel: Ein Fragebogen, der Antworten erzwingt, ist hoch **reliabel** und trotzdem wertlos — er misst nicht die realen Tendenzen.

Nach (Schnell et al. 1999, 6:139) muss eine Studie

1. die theoretischen Beziehungen zwischen den Konstrukten klar benennen
2. diese Beziehungen empirisch beobachtbar machen
3. die gefundenen Beziehungen interpretierbar halten
4. bei neuen Konstrukten einen Erkenntnisgewinn über den Stand hinaus zeigen

Der Kern des Problems

Bei menschenzugewandter Forschungssoftware müssen **Software und ihre Nutzung gemeinsam** evaluiert werden. Die Usability kann zuverlässig hoch gemessen werden, während die intendierte Wirkung der Software auf die Zielgröße gar nicht eintritt.

Theorietransfer

Methode: geliehene Modelle

Modelle, Werte und Best Practices können zwischen Disziplinen **übertragen** (“borrowed”, (Henke 2025)) und als heuristische Analogie (Kornmesser and Büttemeyer 2020) für ein neues Feld rekonstruiert werden.

Explizites Auswahlkriterium statt freier Analogie

Ein Quellmodell wird nur importiert, wenn seine Herkunftsdisziplin eine etablierte, validierte Behandlung eines **Validitätsproblems** besitzt, die dem mensch zugewandten RSE fehlt.


Was importiert wird — und was nicht

Quelle	Beitrag zur Validität
Simulation	eingebauter synthetisch–empirischer Abgleich
Design-Based Research	iterative Verfeinerung unter einem “what could be”-Ziel
Empirische Sozialwissenschaft	Operationalisierung, Gütekriterien

Bewusst nicht importiert

Wasserfall- und anforderungsbasierte SE-Modelle. Ihre Annahme stabiler, extern gegebener Anforderungen gilt nicht mehr, sobald Menschen gleichzeitig Nutzende und Forschungsgegenstand sind.

Quellmodell 2: Design-Based Research




DBR nach (Reinmann 2005): viele iterative Zyklen, in denen Interventionen schrittweise verfeinert werden.

Abgrenzung zu **Design Science Research** (Vom Brocke, Hevner, and Maedche 2020):

- ▶ DBR: iterativ, lauffähige Prototypen entstehen *unterwegs*
- ▶ DSR: parallele Zyklen, Artefakt oft erst *am Ende*

Gemeinsamer Nenner: Fokus auf **Designprinzipien** und eine Vision der Zukunft — in DBR das “what could be”. Der Prozess folgt nicht bloß den Anforderungen, weil diese noch virtuell sind.

Quellmodell 3: Der empirische Forschungsprozess



Nach (Schnell et al. 1999), angepasst um den Simulationszweig und um Marken (RSE), wo RSE auftritt.

Zentral ist die **Operationalisierung**: Variablen werden in messbare Items und vermutete Zusammenhänge zerlegt. Diese Zusammenhänge speisen die *Mechanismen* der Simulation.

Innere RSE-Projekte: Erhebung, Aufzeichnung und Auswertung können je einen eigenen RSE-Prozess enthalten. Diese sind nicht notwendig mensch zugewandt — das vermeidet eine rekursive Modelldefinition.

Wie Forschungssoftware die Studie verändert

Zwei Fälle

Forschungssoftware kann

(i) Beziehungen zwischen Variablen beeinflussen, während das Variablenuniversum im Wesentlichen unverändert bleibt

⇒ Die Studie bliebe auch ohne die Software durchführbar (z.B. mit einem Papierverfahren RS_0).


(ii) den Forschungskontext so **transformieren**, dass die Studie erst mit der Software möglich wird

⇒ Die Software ändert, was als unabhängige Variable gelten kann, was messbar ist, und sogar was als Ergebnis zählt.

Der Unterschied

Im ersten Fall ändert Forschungssoftware, *wie* eine bereits definierbare Studie ausgeführt wird. Im zweiten Fall ändert sie, *welche Studie überhaupt definierbar* ist.

Fall 1: Software beeinflusst Beziehungen




Beispiel: Vokabellernen mit einer Lern-App.

- ▶ *RS* — die App
- ▶ *T* — Übungsintensität
- ▶ *Y* — Vokabelscore
- ▶ *U* — Lernendenmerkmale (Confounder)

Die Software beeinflusst den Pfad von der Übung zum Lernergebnis, führt aber **keine grundsätzlich neuen Variablen** ein. *RS* tritt als Mediator zur Variablenmenge hinzu.

Die Rollen von unabhängiger und abhängiger Variable bleiben stabil.

Fall 2: Software transformiert den Kontext




Beispiel: algorithmische Gruppenbildung in großen Kursen — ohne Software bei komplexen Constraints praktisch unmöglich. Neue **unabhängige** Variablen: A , X . Neue **abhängige** Variablen: G , Y' .

Nicht nur neue Variablen

Auch ihre **Interpretation** ändert sich: Gruppenlernerergebnisse sind nicht die Aggregation individueller Ergebnisse. Das erzwingt einen Rücksprung zu Theorie und Operationalisierung — der Wechsel von empirisch-begründet zu DBR.

Das RIGHT-Framework

Die RIGHT-Entscheidungen



[R]esearch **[I]**ntegrity **[G]**iven
[H]uman-facing **[T]**echnologies

Links die Entscheidungspunkte **D1–D4**, rechts die passenden empirischen Methoden zur Prüfung der Konstruktvalidität. Die vier Knoten tragen die Buchstaben des Merkworts — Figur und Akronym bilden sich direkt aufeinander ab.

Akkumulation

Je komplexer die Forschung durch die Softwareeffekte wird, desto mehr Methoden sind nötig. M1 muss in der Regel von M2–M4 begleitet werden — analog zum Regressionstesten.

D1 [R]elevanz und D2 [H]uman-in-the-Loop

D1 — Ist die Software für die Forschung überhaupt relevant?

Nicht trivial. Technologie-Hypes (aktuell LLMs) verleiten dazu, Technik einzusetzen, obwohl es Alternativen mit weniger verschleiender Wirkung gibt. Auch *ownership*-Gefühle und Pfadabhängigkeit führen zu Softwareentwicklung unabhängig vom Erkenntnisgewinn.

Nein $\Rightarrow$ die empirische Studie läuft normal (S1).

D2 — Gibt es Menschen in der Schleife?

Menschen, die zusätzliche Komplexität durch Bias, zusätzliche Variablen oder Interaktionseffekte erzeugen, weil sie selbst Teil der Analyseeinheit sind.

Nein $\Rightarrow$ klassische Softwareevaluation: Testen, Requirement-Tracing, ggf. formale Verifikation (M4).

D3 — Interagieren die Menschen mit der Forschungsfrage?

Präzisierung von D2. *Nein* $\Rightarrow$ es genügt zu prüfen, dass die Usability (M3) keine organisatorischen Probleme wie Dropouts oder verzerrte Stichproben verursacht.

D4 — Transformiert die Software den Forschungskontext?

Also sowohl die Variablenmenge als auch deren Interpretation (Fall 2).

Nein $\Rightarrow$ der in D3 postulierte Interaktionseffekt muss über **konkurrente Validität** kontrolliert werden: eine Gruppe mit, eine ohne RS-Stimulus (M1). Wo das aus ethischen oder logistischen Gründen nicht geht, hilft ein **Wizard-of-Oz-Design** (M2) — der Effekt der Software wird ohne ihren tatsächlichen Einsatz nachgebildet.

Ja $\Rightarrow$ Design-Based Research (S2).

Der fünfte Buchstabe: [G]eneration

Warum G kein Kaskadenknoten ist

[G]eneration fragt: Können die empirischen Ergebnisse synthetisch erzeugt werden, sodass die Simulationsmethode verfügbar wird?

Das ist bewusst **kein** Knoten in der D1–D4-Kaskade, sondern ein orthogonales **Simulations-Gate an S1**, innerhalb des inneren empirischen Studiendesigns.

Der Grund: Anders als D1–D4 verzweigt es die Kaskade nicht, sondern **ergänzt den empirischen Pfad** — unabhängig davon, wo die Kaskade verlassen wird.

	Merkwort	Frage
D1	[R] elevanz	Ist genau diese RS nötig?
D2	[H] uman-in-the-Loop	Menschen Nutzende <i>und</i> Teil des Kontexts?
D3	[I] nteraktion	Interaktion mit der Forschungsfrage?
D4	[T] ransformation	Neuinterpretation der Variablen erzwungen?
S1	[G] eneration	Ergebnisse synthetisierbar?

Empirische Validierung

Das RIGHT-Modell ist theoretisch über Theorietransfer hergeleitet — aber seine Entscheidungspunkte machen **empirisch prüfbare Aussagen**.

Testfall: die DELFI-Proceedings 2003–2025, $n = 266$ Publikationen mit konkretem empirischen Studiensetting (Dehne, Lochner, and Wiepke 2026). Eine Community, die sehr aktiv Software entwickelt *und* im menschengewandten Bildungskontext forscht.

Annotiert per Mehrheitsentscheid dreier quelloffener LLMs — die Übereinstimmung liegt bei rund 0.8.

Das Codebuch als Operationalisierung

Der Prompt operationalisiert das RIGHT-Framework direkt: jede Publikation wird mit **D1–D4** und den sechs empfohlenen Methoden (**S1, S2, M1–M4**) binär annotiert.

Warum das methodisch zählt

Das Codebuch legt fest, welche Textevidenz eine annotierende Instanz finden muss — auch für das sonst abstrakte Urteil, ob die Software den Forschungskontext *transformiert* (D4).


Wenn das Messinstrument selbst ein Modell ist

Zwei Beobachtungen aus der Annotation:

- ▶ Die Modelle sind unterschiedlich **liberal** — dasselbe Paper wird je nach Modell systematisch anders kodiert.
- ▶ Zwei Modelle **derselben Familie** stimmten miteinander weit stärker überein als mit jedem anderen Modell.

Der methodische Punkt

Ein Mehrheitsentscheid über verwandte Modelle misst nicht mehr Konsens, sondern Modellverwandtschaft. Die Wahl des Ensembles ist selbst eine **Validitätsfrage** — das Instrument ist Teil des Forschungskontexts, nicht neutral dazu.



Die RIGHT-Kaskade, annotiert mit dem DELFI-Korpus ($n = 266$, Mehrheitsentscheid dreier LLMs).

Wo die Praxis dem Modell folgt — und wo nicht

Im Rahmen

M4 Softwareevaluation und **M3** Usability-Evaluation werden etwa so breit angewandt, wie das Modell sie vorschreibt.

S2 Design-Based Research ist die einzige Methode, die *häufiger* angewandt wird als gefordert.

Die Lücken

S1 empirische Studie: 94% sollten, nur 33% tun es

M1 ∨ **M2** Kontrolle der Interaktionseffekte: 60% sollten, nur 13% tun es

Die wahrscheinlichste Erklärung der S1-Lücke: Die Papers enden mit der Präsentation der methodischen Ergebnisse, **ohne die ursprünglich intendierte Studie je zu erreichen.**

Kernaussage

Die Community evaluiert die **Software** und ihre **Usability** etwa so breit, wie das Modell es verlangt. Aber sie rahmt die Arbeit selten als kontrollierte empirische Studie (S1) und implementiert fast nie die Kontrolle der konkurrenten Validität (M1 ∨ M2), die das Modell fordert, sobald D2 und D3 bejaht sind.

Weil D4 nur für 6% bejaht wird, schickt die Kaskade **94% der verbleibenden Studien den D4=“nein“-Zweig hinunter** — also genau dorthin, wo M1/M2 verpflichtend wäre.

⇒ Genau das ist der Validitäts-blinde-Fleck, den RIGHT sichtbar machen soll: **Je stärker die Forschungssoftware mit der menschzugewandten Forschungsfrage interagiert, desto mehr wird die fehlende Kontrolle der konkurrenten Validität zur Bedrohung der Konstruktvalidität.**

Einordnung

- ▶ **Scope:** die Schnittmenge aus empirischen Studien, RSE und Design-Based Research. Manche Ideen verallgemeinern sich auf andere Disziplinen weniger nützlich.
- ▶ **Die empirische Validierung ist beobachtend.** Sie zeigt, *wo* berichtete Praxis vom Modell abweicht — noch nicht, *ob* das Befolgen des Modells zu besseren methodischen Entscheidungen führt.
- ▶ **LLM-Annotation statt menschlicher Kodierung.** Die Übereinstimmung ist gut, aber die Labels messen, was in den Papers *berichtet* wird, nicht was tatsächlich *getan* wurde.
- ▶ **Objektivität**, das dritte Gütekriterium, bleibt vollständig außen vor.

Ziel: eine **Typologie der Forschungssoftware**, die informatische Forschung überhaupt hervorbringt — über das GI-LNI-Korpus statt nur über DELFI.

Offene Frage dabei: **binär robust, ordinal fragil**. Ob ein Paper Forschungssoftware produziert, lässt sich zuverlässig kodieren — Art, Reifegrad und Rolle im Forschungsdesign bisher nicht. Der Engpass ist die Operationalisierung, nicht das Instrument.

To be FAIR or to be RIGHT?

Die Antwort ist: **beides zählt** für nachhaltige Forschung. Die FAIR-Prinzipien adressieren die Reliabilität und sind unverzichtbar. Aber sie sind für menschzugewandte Forschungssoftware nicht hinreichend.

- ▶ Aus Simulation, DBR, klassischem SE und empirischer Forschung lässt sich ein **Meta-Entscheidungsmodell** synthetisieren, das Konstruktvalidität in komplexen menschzugewandten Szenarien absichert.
- ▶ Die Praxis im DELFI-Korpus berücksichtigt die **Interaktionseffekte klar nicht**.
- ▶ Für die eScience-Community bleibt offen, Methoden und Prozessmodelle zu entwickeln, die solche Effekte **systematisch messbar** machen.

Nächster Schritt: die dritte Güte-Dimension, **Objektivität**.

Wo in Ihren eigenen Projekten liegt der Ausstieg aus der Kaskade?

D1 [R]elevanz → D2 [H]uman-in-the-Loop → D3 [I]nteraktion → D4
[T]ransformation

Und: wann haben Sie zuletzt eine Kontrollbedingung ohne die Software gerechnet?

- Barker, Michelle, Neil P. Chue Hong, Daniel S. Katz, Anna-Lena Lamprecht, Carlos Martinez-Ortiz, Fotis Psomopoulos, Jennifer Harrow, et al. 2022. "Introducing the FAIR Principles for Research Software." *Scientific Data* 9 (1): 622. <https://doi.org/10.1038/s41597-022-01710-x>.
- Brett, Alys, Michael Croucher, Robert Haines, Simon Hettrick, James Hetherington, Mark Stillwell, and Claire Wyatt. 2017. "Research Software Engineers: State Of The Nation Report 2017," April. <https://doi.org/10.5281/ZENODO.495360>.
- Dehne, Julian, Sebastian Christ, Fabian Goth, Jan-Niklas Grad, Magnus Hagdorn, Jan P. Thiele, Harald von Waldow, and Jonas Linxweiler. 2025. "Research Software Engineering for Natural Sciences." In *Softwaretechnik-Trends*, edited by Andrea Herrmann. Vol. 45. 3. Berlin: Gesellschaft für Informatik e.V.

- Dehne, Julian, Fabian Lochner, and Axel Wiepke. 2026. “Research Software Engineering in the Learning Technologies: a replication study of research paradigms in the DELFI community.” In *DELFI 2026 – Die 24. Fachtagung Bildungstechnologien Der Gesellschaft Für Informatik (GI)*. Lecture Notes in Informatics (LNI). Bonn: Gesellschaft für Informatik.
- Drogoul, Alexis, Diane Vanbergue, and Thomas Meurisse. 2003. “Multi-Agent Based Simulation: Where Are the Agents?” In *Multi-Agent-Based Simulation II*, edited by Jaime Simão Sichman, François Bousquet, and Paul Davidsson, 1–15. Berlin, Heidelberg: Springer. https://doi.org/10.1007/3-540-36483-8_1.
- Felderer, Michael, Michael Goedicke, Lars Grunske, Wilhelm Hasselbring, Anna-Lena Lamprecht, and Bernhard Rumpe. 2025. “Investigating Research Software Engineering: Toward RSE Research.” *Communications of the ACM* 68 (2): 20–23.

- Gruenpeter, Morane, Daniel S. Katz, Anna-Lena Lamprecht, Tom Honeyman, Daniel Garijo, Alexander Struck, Anna Niehues, et al. 2021. "Defining Research Software: A Controversial Discussion." Zenodo.
<https://doi.org/10.5281/ZENODO.5504016>.
- Henke, Jakob. 2025. "Theory Borrowing as a Process." MediArXiv.
https://doi.org/10.33767/osf.io/zvgy2_v2.
- Kornmesser, Stephan, and Wilhelm Büttemeyer. 2020. *Wissenschaftstheorie: Eine Einführung*. Stuttgart: J.B. Metzler. <https://doi.org/10.1007/978-3-476-04743-4>.
- Kuhn, Thomas S. 1994. *The Structure of Scientific Revolutions*. 2. ed., enlarged, 21. print. International Encyclopedia of Unified Science 2,2. Chicago: Univ. of Chicago Press.

- Reinmann, Gabi. 2005. "Innovation ohne Forschung? Ein Plädoyer für den Design-Based Research-Ansatz in der Lehr-Lernforschung." *Unterrichtswissenschaft* 33 (1): 52–69.
- Schnell, Rainer, Paul B Hill, Elke Esser, et al. 1999. *Methoden der empirischen Sozialforschung*. Vol. 6. R. Oldenbourg München ua.
- Vom Brocke, Jan, Alan Hevner, and Alexander Maedche. 2020. "Introduction to Design Science Research." In *Design Science Research. Cases*, edited by Jan Vom Brocke, Alan Hevner, and Alexander Maedche, 1–13. Cham: Springer International Publishing. https://doi.org/10.1007/978-3-030-46781-4_1.
- Wissenschaftsrat. 2012. "Empfehlungen Zur Weiterentwicklung Der Wissenschaft-Lichen Informationsinfrastrukturen in Deutschland Bis 2020." Wissenschaftsrat.